ЛЕКЦИЯ 3. ОЦЕНКА МОМЕНТОВ ПО ГРУППИРОВАННОЙ ВЫБОРКЕ

Полная версия с сохранением содержания и детальной расшифровкой каждой формулы

Основано на материале «Лекция 3 (2).pdf»

Далее приводится текст, сохраняющий основную структуру и ключевые фрагменты исходной лекции, но дополненный двумя обязательными слоями пояснений: (1) перед каждой формулой уточняется *где именно* она применяется (в каком месте рассуждения и зачем), (2) под каждой формулой перечисляются *все компоненты* (что означает каждый символ и индекс). Источник исходного материала: **:contentReference[oaicite:0]index=0**.

1. Моменты: что это и зачем мы их оцениваем

Мы продолжаем говорить об оценивании моментов выборки. Как указывалось ранее, при большом объёме выборки и в предположении, что генеральная совокупность имеет непрерывное распределение, выборочный закон распределения удобно представлять в виде *группированной выборки* и строить гистограмму. Возникает вопрос: как надо изменить формулы для оценки основных моментов в этом случае и как это изменение повлияет на качество оценивания?

1.1. Определение момента (добавлено, чтобы понятие не «появлялось из воздуха»)

Определение 1 (Момент)**.** *Пусть X — случайная величина. Начальным моментом порядка k называется*

$$m_k = \mathbb{E}(X^k).$$

Где применяется. Это «теоретическое» определение для генеральной совокупности; в выборке мы заменяем $\mathbb{E}(\cdot)$ на среднее по данным и получаем выборочные моменты.

Компоненты: m_k — момент порядка k; $\mathbb{E}(\cdot)$ — математическое ожидание; X — случайная величина; k — порядок момента (целое число $k = 1, 2, 3, \dots$).

2. Группированная выборка: формулы из лекции и расшифровка каждого символа

Представляется естественным использовать следующие формулы.

Определение 2 (Группировка и оценки моментов по группированной выборке)**.** *Пусть диапазон возможных значений выборки $[X_0; X_m]$ разбит на m промежутков*

$$[X_0, X_1),\ [X_1, X_2),\ \dots,\ [X_{m-1}, X_m],$$

причём в каждый из них попало $n_1, n_2, \ldots, n_m$ элементов выборки. Тогда оценки выборочных моментов будем вычислять по формулам

$$\widehat{X}_g = \frac{1}{n}\sum_{k=1}^{m} n_k \widehat{X}_k, \qquad \widehat{\sigma}_g^2 = \frac{1}{n-1}\sum_{k=1}^{m} n_k \big(\widehat{X}_k - \widehat{X}_g\big)^2,$$

где $\widehat{X}_k$ — середина интервала $[X_{k-1}, X_k)$:

$$\widehat{X}_k = \frac{X_{k-1} + X_k}{2}.$$

Замечание 1. *Предложенные формулы фактически «считают», что все элементы выборки, попавшие в один промежуток, равны между собой и равны середине интервала.*

2.1. Формула для $\widehat{X}_g$ (среднего по группировке): где применяется и что означает каждый символ

Формула:

$$\widehat{X}_g = \frac{1}{n}\sum_{k=1}^{m} n_k \widehat{X}_k.$$

Где применяется. Используется вместо обычного выборочного среднего, когда данные не хранятся поштучно (каждое X_i), а представлены гистограммой: известны интервалы и частоты n_k.

Компоненты: $\widehat{X}_g$ — оценка выборочного среднего по *группированной* выборке (буква g — grouping); n — общий объём выборки (число всех наблюдений); $\sum_{k=1}^{m}$ — суммирование по всем интервалам гистограммы; m — число интервалов (столбиков гистограммы); k — номер интервала ($k = 1, 2, \ldots, m$); n_k — сколько наблюдений попало в k-й интервал; $\widehat{X}_k$ — середина k-го интервала, которой мы заменяем все значения внутри этого интервала.

2.2. Формула для $\widehat{\sigma}_g^2$ (дисперсии по группировке): где применяется и что означает каждый символ

Формула:

$$\widehat{\sigma}_g^2 = \frac{1}{n-1}\sum_{k=1}^{m} n_k \big(\widehat{X}_k - \widehat{X}_g\big)^2.$$

Где применяется. Используется вместо обычной выборочной дисперсии, когда мы не видим каждое наблюдение X_i, а считаем, что все X_i внутри интервала равны середине $\widehat{X}_k$.

Компоненты: $\widehat{\sigma}_g^2$ — оценка выборочной дисперсии по группированной выборке; $n-1$ — поправка Бесселя (деление на $n-1$ вместо n для несмещённости); n_k — число наблюдений в интервале k (вес этого интервала); $\widehat{X}_k - \widehat{X}_g$ — отклонение середины интервала от группированного среднего; $(\cdot)^2$ — квадрат отклонения (как в определении дисперсии); сумма по k — «складываем вклад всех интервалов».

2.3. Формула для середины интервала $\widehat{X}_k$: где применяется и что означает каждый символ

Формула:

$$\widehat{X}_k = \frac{X_{k-1} + X_k}{2}.$$

Где применяется. Нужна для того, чтобы заменить все значения внутри интервала $[X_{k-1}, X_k)$ одним «типичным» значением.

Компоненты: $\widehat{X}_k$ — середина k-го интервала; X_{k-1} — левая граница k-го интервала; X_k — правая граница k-го интервала; деление на 2 — потому что середина — это полусумма границ.

3. Иллюстрация 1 (из лекции): подпись и смысл

В лекции приводится пример с ростом студентов, где сравниваются значения выборочного среднего и дисперсии с соответствующими значениями после группировки при ширине интервала 10 см и 5 см.

Иллюстрация 1. Сравнение точных выборочных характеристик (среднее, дисперсия) и оценок по группировке $\widehat{X}_g$, $\widehat{\sigma}_g^2$ при различной ширине интервалов гистограммы.

Где применяется. Эта иллюстрация нужна для мотивации: даже «простая» группировка влияет на среднее и особенно на дисперсию.

4. Оценка отличий: что происходит при группировке со средним и дисперсией

Далее в исходной лекции последовательно оцениваются ошибки для среднего и дисперсии.

4.1. (1) Интервал, его длина, середина и набор индексов

Пусть интервал $[x_{k-1}, x_k)$ имеет длину

$$h_k = x_k - x_{k-1},$$

середину

$$\widehat{x}_k = \frac{x_{k-1} + x_k}{2},$$

и содержит n_k элементов выборки.

Где применяется. Эти определения используются в оценке ошибки, когда реальные значения x_i внутри интервала заменяют на середину $\widehat{x}_k$.

Компоненты формулы длины интервала: h_k — длина (ширина) k-го интервала; x_k — правая граница интервала; x_{k-1} — левая граница интервала.

Компоненты формулы середины: $\widehat{x}_k$ — середина интервала; x_{k-1}, x_k — границы; деление на 2 — полусумма.

Обозначим через I_k набор индексов наблюдений, попавших в k-й интервал:

$$I_k = \{\, i : \; x_i \in [x_{k-1}, x_k) \,\}, \qquad |I_k| = n_k.$$

Где применяется. Множества I_k позволяют корректно переписать сумму по всем $i = 1, \ldots, n$ как сумму по интервалам и затем по элементам внутри интервала.

Компоненты: I_k — множество индексов наблюдений в интервале k; x_i — конкретное наблюдение (значение признака); $|I_k|$ — мощность множества (сколько индексов); n_k — число наблюдений в интервале.

4.2. Точное среднее и группированное среднее: две суммы

Точное выборочное среднее:

$$\overline{x} = \frac{1}{n} \sum_{i=1}^{n} x_i.$$

Где применяется. Это «правильное» среднее, если у нас есть все исходные данные x_i.

Компоненты: $\overline{x}$ — выборочное среднее (по сырым данным); n — размер выборки; x_i — i-е наблюдение; $\sum_{i=1}^{n}$ — сумма по всем наблюдениям.

Ту же сумму можно переписать по интервалам:

$$\sum_{i=1}^{n} x_i = \sum_{k=1}^{m} \sum_{i \in I_k} x_i, \qquad \Rightarrow \qquad \overline{x} = \frac{1}{n} \sum_{k=1}^{m} \sum_{i \in I_k} x_i.$$

Где применяется. Это переписывание нужно, чтобы затем вычесть из него группированную сумму, где вместо x_i стоят $\widehat{x}_k$.

Компоненты: m — число интервалов; k — номер интервала; I_k — индексы в интервале; внутренняя сумма $\sum_{i \in I_k}$ — складывает наблюдения внутри интервала; внешняя сумма $\sum_{k=1}^{m}$ — складывает суммы интервалов.

Группированное среднее:

$$\widehat{x}_g = \frac{1}{n} \sum_{k=1}^{m} n_k \widehat{x}_k.$$

Где применяется. Это среднее, которое реально считается по гистограмме (частотам и серединам интервалов).

Компоненты: $\widehat{x}_g$ — среднее по группировке; n_k — частота интервала k; $\widehat{x}_k$ — середина интервала k.

4.3. Погрешность для среднего: вывод формулы разности

В лекции вводится погрешность для среднего:

$$\Delta = \overline{x} - \widehat{x}_g.$$

Где применяется. Эта разность измеряет, насколько группировка и замена наблюдений на середины интервалов «исказили» среднее.

Компоненты: Δ — погрешность (ошибка) среднего; $\overline{x}$ — точное выборочное среднее; $\widehat{x}_g$ — среднее по группировке.

Подставим выражения:

$$\Delta = \frac{1}{n}\sum_{k=1}^{m}\sum_{i\in I_k} x_i - \frac{1}{n}\sum_{k=1}^{m}\sum_{i\in I_k}\widehat{x}_k = \frac{1}{n}\sum_{k=1}^{m}\sum_{i\in I_k}(x_i - \widehat{x}_k).$$

Где применяется. Это ключевая формула: ошибка среднего — это среднее по всем «ошибкам замены» $x_i \mapsto \widehat{x}_k$.

Компоненты: $(x_i - \widehat{x}_k)$ — ошибка замены конкретного наблюдения x_i серединой интервала; двойная сумма — суммирование этих ошибок по всем интервалам и всем наблюдениям.

4.4. (2) Оценка погрешности в одном интервале

Определим отклонение некоторого значения из интервала от его середины:

$$\varepsilon_i = x_i - \widehat{x}_k, \qquad i \in I_k.$$

Где применяется. Это «локальная» ошибка внутри конкретного интервала: насколько x_i отличается от середины.

Компоненты: ε_i — отклонение i-го наблюдения от середины своего интервала; x_i — наблюдение; $\widehat{x}_k$ — середина интервала, куда попало x_i; условие $i \in I_k$ — x_i действительно в интервале k.

Очевидно, что

$$|\varepsilon_i| \le \frac{h_k}{2}.$$

Где применяется. Эта оценка нужна для грубой оценки максимальной ошибки, потому что дальше суммарная ошибка по интервалу будет суммой ε_i.

Компоненты: $|\varepsilon_i|$ — модуль отклонения; h_k — длина интервала; деление на 2 — максимальное расстояние от середины до границы.

Суммарная погрешность по интервалу:

$$\Delta_k = \sum_{i\in I_k}\varepsilon_i.$$

Где применяется. Это ошибка «в интервале целиком»: если все x_i заменили на $\widehat{x}_k$, то насколько изменилась сумма в этом интервале.

Компоненты: Δ_k — суммарная ошибка интервала k; $\sum_{i\in I_k}$ — сумма по элементам интервала; ε_i — локальные отклонения.

4.5. (3) Равномерное распределение внутри интервала: ожидание и дисперсия ошибки

Предположим, что внутри каждого интервала наблюдения распределены равномерно относительно середины. Тогда среднее отклонение равно нулю:

$$\mathbb{E}(\varepsilon_i) = 0, \qquad \Rightarrow \qquad \mathbb{E}(\Delta) = 0.$$

Где применяется. Это объясняет фразу в лекции: «в среднем ошибки нет, оценка несмещенная» (для среднего).

Компоненты: $\mathbb{E}(\varepsilon_i)$ — математическое ожидание локальной ошибки; $\mathbb{E}(\Delta)$ — ожидание общей ошибки среднего.

Дисперсия равномерного распределения на отрезке длины h_k:

$$\mathbb{D}(\varepsilon_i) = \frac{h_k^2}{12}.$$

Где применяется. Это величина «типичного квадратичного размера» ошибки внутри интервала; она затем участвует в оценке дисперсии общей ошибки.

Компоненты: $\mathbb{D}(\varepsilon_i)$ — дисперсия локальной ошибки; h_k — ширина интервала; 12 — постоянная из формулы дисперсии равномерного распределения.

Если интервалы одинаковой ширины $h_k = h$, то разброс ошибки среднего растёт линейно с h и убывает пропорционально n (в духе выводов лекции).

5. (4) Ошибка для выборочной дисперсии: разложение на меж- и внутриинтервальную части

В лекции используется разложение отклонения от среднего:

$$x_i - \overline{x} = (x_i - \widehat{x}_k) + (\widehat{x}_k - \overline{x}).$$

Где применяется. Это главный приём, чтобы понять, почему группированная дисперсия учитывает только межинтервальную часть и теряет внутриинтервальную.

Компоненты: x_i — наблюдение; $\overline{x}$ — точное среднее; $\widehat{x}_k$ — середина интервала, куда попало x_i; $x_i - \widehat{x}_k$ — внутриинтервальное отклонение; $\widehat{x}_k - \overline{x}$ — отклонение середины интервала от среднего (межинтервальная часть).

Возводим в квадрат:

$$(x_i - \overline{x})^2 = (x_i - \widehat{x}_k)^2 + (\widehat{x}_k - \overline{x})^2 + 2(x_i - \widehat{x}_k)(\widehat{x}_k - \overline{x}).$$

Где применяется. После суммирования по i внутри интервала смешанный член часто исчезает (при симметрии), и получается сумма двух дисперсий.

Компоненты: $(x_i - \widehat{x}_k)^2$ — вклад внутри интервала; $(\widehat{x}_k - \overline{x})^2$ — вклад между интервалами; удвоенное произведение — смешанный член.

Далее при суммировании (как в лекции) получается разложение:

$$\sum_{i=1}^{n}(x_i-\overline{x})^2 = \underbrace{\sum_{k=1}^{m} n_k(\widehat{x}_k-\overline{x})^2}_{\text{межинтервальная часть}} + \underbrace{\sum_{k=1}^{m}\sum_{i\in I_k}(x_i-\widehat{x}_k)^2}_{\text{внутриинтервальная часть}} \quad \text{(при исчезновении смешанного члена).}$$

Где применяется. Это объясняет вывод лекции: группированная дисперсия занижает настоящую дисперсию, потому что при группировке внутренняя часть «теряется».

Компоненты: левая часть — суммарная квадратичная сумма отклонений от среднего; первая правая сумма — межинтервальная «дисперсия середин»; вторая правая сумма — внутриинтервальный разброс.

В лекции делается вывод, что группированная дисперсия занижает истинную дисперсию примерно на величину порядка $h^2/12$ (при одинаковом шаге группировки).

6. ОПТИМАЛЬНОСТЬ ОЦЕНОК: MSE и разложение на дисперсию и смещение

Вернёмся к разговору о качестве оценивания. Опишем общий подход.

Определение 3. *Оценку $\widehat{\theta}$ называют оптимальной, если она минимизирует заданный критерий качества.*

Где применяется. Это рамка для сравнения разных оценок одного и того же параметра (например, среднего): надо выбрать критерий качества и минимизировать его.

Компоненты: θ — истинный параметр (например, математическое ожидание μ); $\widehat{\theta}$ — оценка параметра по данным.

6.1. Определение MSE

Определение 4 (MSE)**.** *Среднеквадратической ошибкой оценки параметра θ называют величину*

$$\mathrm{MSE}(\widehat{\theta}) = \mathbb{E}\big[(\widehat{\theta}-\theta)^2\big].$$

Где применяется. MSE используется как критерий качества, который учитывает и разброс оценки, и её систематическое смещение.

Компоненты: $\mathrm{MSE}(\widehat{\theta})$ — среднеквадратичная ошибка; $\mathbb{E}(\cdot)$ — ожидание по повторным выборкам; $\widehat{\theta}-\theta$ — ошибка оценки; квадрат — штрафует большие ошибки сильнее.

6.2. Разложение MSE: каждый шаг и каждый символ

Добавим и вычтем $\mathbb{E}\widehat{\theta}$:

$$\widehat{\theta}-\theta = (\widehat{\theta}-\mathbb{E}\widehat{\theta}) + (\mathbb{E}\widehat{\theta}-\theta).$$

Где применяется. Это стандартный приём, чтобы отделить случайную часть (колебания вокруг среднего) от систематической (смещения).

Компоненты: $\mathbb{E}\widehat{\theta}$ — среднее значение оценки при повторении эксперимента; $\widehat{\theta}-\mathbb{E}\widehat{\theta}$ — «случайное отклонение»; $\mathbb{E}\widehat{\theta}-\theta$ — смещение (bias).

Далее получаем:

$$\mathrm{MSE}(\widehat{\theta}) = \mathbb{D}(\widehat{\theta}) + \big(\mathbb{E}\widehat{\theta}-\theta\big)^2.$$

Где применяется. Эта формула объясняет, почему иногда небольшое смещение может быть выгодно, если оно резко уменьшает дисперсию и тем самым уменьшает MSE.

Компоненты: $\mathbb{D}(\widehat{\theta})$ — дисперсия оценки (случайный разброс); $(\mathbb{E}\widehat{\theta}-\theta)^2$ — квадрат смещения (систематическая ошибка).

7. ЭФФЕКТИВНАЯ ОЦЕНКА: что означает и почему зависит от закона

Определение 5 (Эффективная оценка)**.** *Эффективная оценка параметра θ — это несмещённая оценка, имеющая минимальную дисперсию среди всех несмещённых оценок параметра.*

Где применяется. Когда принципиально важно, чтобы оценка была несмещённой (в среднем совпадала с параметром), сравнивают дисперсии несмещённых оценок и выбирают минимальную.

Компоненты: несмещённость: $\mathbb{E}\widehat{\theta}=\theta$; минимальная дисперсия: $\mathbb{D}(\widehat{\theta})$ минимальна.

Пример из лекции: при нормальном распределении выборочное среднее имеет меньшую дисперсию, чем медиана; при равномерном распределении полуразмах может иметь меньшую дисперсию, чем среднее.

8. ФУНКЦИЯ ПОТЕРЬ, РИСК, БАЙЕСОВСКИЙ И МИНИМАКСНЫЙ ПОДХОДЫ

Определение 6 (Функция потерь)**.** *Функцией потерь $L(\theta,\widehat{\theta})$ называют величину, характеризующую ошибку при замене θ на $\widehat{\theta}$.*

Где применяется. В задачах принятия решений: ошибка может «стоить» поразному в зависимости от контекста.

Компоненты: L — функция потерь; θ — истинный параметр; $\widehat{\theta}$ — оценка.

Определение 7 (Риск)**.** *Риск при фиксированном θ:*

$$R(\theta,\widehat{\theta}) = \mathbb{E}_\theta\big[L(\theta,\widehat{\theta})\big].$$

Где применяется. Чтобы сравнивать оценки по средней потере (в среднем по выборкам).

Компоненты: R — риск; $\mathbb{E}_\theta$ — ожидание при данном истинном θ; L — потери.

Далее:

$$r(\widehat{\theta}) = \int R(\theta, \widehat{\theta})\pi(\theta)\, d\theta$$

— байесовский средний риск, и

$$\sup_\theta R(\theta, \widehat{\theta})$$

— максимальный риск (минимаксный критерий).

Где применяется. Байесовский подход — когда есть априорная информация; минимакс — когда готовимся к худшему случаю.

Конец файла.