Практика 2: Работа с гистограммой распределения

очень подробные пояснения, теория и расчёты (Overleaf-ready)

Важная установка перед расчётами

Главная идея практики: **сначала смотрим на график, потом считаем статистики**. Одна и та же численная характеристика (например, среднее) может соответствовать совершенно разным формам данных. Поэтому анализ начинаем с гистограммы, а уже затем используем среднее, медиану, дисперсию, асимметрию и эксцесс.

Эта практика разбирает 5 типовых ситуаций, которые встречаются в задачниках и в реальных данных: (1) близкое к нормальному распределение, (2) смесь двух нормальных распределений (бимодальность), (3) экспоненциальное распределение, (4) равномерное распределение, (5) нормальное распределение, но с выбросами.

Часть A. Базовая теория (минимум, который нужен, но очень подробно)

A1. Что такое гистограмма и как её читать

Гистограмма — это разбиение оси значений на интервалы (бины) и подсчёт, сколько наблюдений попало в каждый интервал.

Пусть есть выборка $x_1, \ldots, x_n$. Разобьём числовую ось на интервалы одинаковой ширины h:

$$[a_0, a_1),\ [a_1, a_2),\ \ldots,\ [a_{m-1}, a_m), \quad a_k = a_0 + kh.$$

Если N_k — число наблюдений, попавших в k-й интервал, то:

- **частотная гистограмма**: высота столбца $\propto N_k$;
- **гистограмма плотности**: высота столбца $\propto \dfrac{N_k}{nh}$ так, чтобы суммарная площадь была 1.

Что мы **визуально** ищем на гистограмме:

- **сколько пиков (мод)**: один пик (унимодальная), два пика (бимодальная), много пиков;
- **симметрия/асимметрия**: хвосты одинаковые или один хвост длиннее;
- **хвосты**: длинные хвосты дают сильное влияние редких больших/малых значений;
- **выбросы**: отдельные столбики далеко от основной массы.

A2. Центральные тенденции: среднее, медиана, мода

Выборочное среднее.

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Среднее использует **все** наблюдения, поэтому очень чувствительно к выбросам и хвостам.

Медиана. Если отсортировать выборку:

$$x_{(1)} \le x_{(2)} \le \cdots \le x_{(n)},$$

то медиана:

$$\mathrm{Me} = \begin{cases} x_{(\frac{n+1}{2})}, & n \text{ нечётное}, \\ \dfrac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}, & n \text{ чётное}. \end{cases}$$

Медиана делит выборку пополам: 50% наблюдений не больше медианы и 50% не меньше медианы. Она **устойчивее** к выбросам.

Мода. Мода — значение, которое встречается чаще всего; для непрерывных данных чаще говорят «пик гистограммы». Если распределение многовершинное, то мод может быть несколько.

Связь среднего/медианы/моды при асимметрии. Если распределение **правоскошенное** (длинный хвост вправо), то обычно:

$$\text{мода} < \text{медиана} < \text{среднее}.$$

Если распределение **левоскошенное** (длинный хвост влево), то обычно:

$$\text{среднее} < \text{медиана} < \text{мода}.$$

Эта связь прямо указана в вашем файле практики (см. формулировки про асимметрию).

A3. Меры разброса: дисперсия и стандартное отклонение

Выборочная дисперсия. В статистике чаще используют исправленную дисперсию:

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \overline{x})^2.$$

Стандартное отклонение.

$$s = \sqrt{s^2}.$$

Интерпретация: «типичный масштаб отклонения» наблюдений от среднего (если распределение не слишком кривое и без выбросов).

A4. Асимметрия и эксцесс (формулы и смысл)

В файле практики приведены выборочные коэффициенты асимметрии и эксцесса.

Выборочная асимметрия. В вашей практике используется формула вида

$$\gamma_1 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \overline{x}}{s}\right)^3.$$

Смысл:

- $\gamma_1 \approx 0$ — распределение примерно симметрично (часто близко к нормальному);
- $\gamma_1 > 0$ — длинный хвост справа (правосторонняя асимметрия);
- $\gamma_1 < 0$ — длинный хвост слева (левосторонняя асимметрия).

Выборочный эксцесс. В вашей практике используется эксцесс (куртозис минус 3):

$$\gamma_2 = \frac{1}{n}\sum_{i=1}^{n}\left(\frac{x_i - \overline{x}}{s}\right)^4 - 3.$$

Смысл:

- $\gamma_2 \approx 0$ — «как у нормального» по остроте пика/хвостам;
- $\gamma_2 > 0$ — более тяжёлые хвосты/более высокий пик (часто признак выбросов или «тяжёлых хвостов»);
- $\gamma_2 < 0$ — более плоское распределение (часто как у равномерного).

Практическое правило внимательности (из вашего файла). Если $|\gamma_1| > 0.5$ или $|\gamma_2| > 0.5$, то это уже заметное отклонение от «почти нормального» поведения и требует осторожности при интерпретации.

A5. Какие распределения «бывают» и какие формулы у них

Поскольку в практике фигурируют нормальное, равномерное, экспоненциальное и смесь нормальных, выпишем их базовые формулы.

A5.1 Нормальное распределение

Обозначение: $X \sim \mathcal{N}(\mu, \sigma^2)$.

Плотность:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}}\exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right).$$

Ключевые характеристики:

$$\mathbb{E}X = \mu, \qquad \mathrm{Var}(X) = \sigma^2, \qquad \mathrm{Me} = \mu, \qquad \gamma_1 = 0, \qquad \gamma_2 = 0.$$

Почему «среднее почти равно медиане» при нормальности: распределение симметрично относительно μ, поэтому центр «по среднему» и центр «по половинкам» совпадают.

A5.2 Равномерное распределение

Обозначение: $X \sim U(a, b)$, где все значения на $[a, b]$ примерно одинаково вероятны.

Плотность:

$$f(x) = \begin{cases} \dfrac{1}{b-a}, & x \in [a, b], \\ 0, & \text{иначе.} \end{cases}$$

Характеристики:

$$\mathbb{E}X = \frac{a+b}{2}, \qquad \mathrm{Var}(X) = \frac{(b-a)^2}{12}, \qquad \mathrm{Me} = \frac{a+b}{2}.$$

Эксцесс равномерного распределения отрицательный (распределение «плоское»), что согласуется с наблюдением в практике.

A5.3 Экспоненциальное распределение

Обозначение: $X \sim \mathrm{Exp}(\lambda)$, $\lambda > 0$.

Плотность:

$$f(x) = \lambda e^{-\lambda x}, \qquad x \geq 0.$$

Характеристики:

$$\mathbb{E}X = \frac{1}{\lambda}, \qquad \mathrm{Var}(X) = \frac{1}{\lambda^2}.$$

Медиана для экспоненциального распределения:

$$\mathrm{Me} = \frac{\ln 2}{\lambda}.$$

Так как $\ln 2 \approx 0.693 < 1$, то медиана меньше среднего:

$$\mathrm{Me} = \frac{\ln 2}{\lambda} < \frac{1}{\lambda} = \mathbb{E}X.$$

Это ровно тот эффект, который вы видите в практике: при правой асимметрии среднее больше медианы.

A5.4 Смесь распределений (пример: смесь двух нормальных)

Если данные получены как смесь двух подгрупп, то модель может быть:

$$X \sim p\,\mathcal{N}(\mu_1, \sigma_1^2) + (1-p)\,\mathcal{N}(\mu_2, \sigma_2^2), \quad 0 < p < 1.$$

Плотность смеси:

$$f(x) = p\, f_1(x) + (1-p)\, f_2(x),$$

где f_1, f_2 — плотности нормальных компонент.

Среднее смеси:

$$\mathbb{E}X = p\mu_1 + (1-p)\mu_2.$$

Важный вывод: **среднее смеси может попадать в «провал» между пиками** и не быть «типичным» для реальных наблюдений.

A6. Кластеризация как технический инструмент при бимодальности (k-means)

Если видим два пика, но не знаем причину, можно **технически** разделить выборку на две группы.

Классический алгоритм k-means при $k = 2$:

1. задать начальные центры c_1, c_2;
2. каждую точку x_i отнести к ближайшему центру по расстоянию (в 1D: по модулю $|x_i - c_j|$);
3. пересчитать центры как средние внутри групп:

$$c_1 = \frac{1}{n_1} \sum_{x_i \in G_1} x_i, \qquad c_2 = \frac{1}{n_2} \sum_{x_i \in G_2} x_i;$$

4. повторять шаги 2–3, пока центры не перестанут меняться (стабилизация).

Важно: кластеризация **не объясняет причину** двух пиков, она только помогает выделить подгруппы для дальнейшего анализа предметной области.

Часть B. Очень подробный разбор примеров из «Практики 2»

Ниже я переписываю каждый из 5 примеров **очень подробно**, добавляя: что видно на гистограмме, какие статистики что означают, почему среднее/медиана так себя ведут, и какие формулы за этим стоят.

Пример 1. Нормальное распределение (выборка $n = 100$)

Дано (по практикуму): среднее 50.32, медиана 51.26, дисперсия 103.29, $s = 10.16$, асимметрия $\gamma_1 = -0.31$, эксцесс $\gamma_2 = 0.95$.

1.1 Что видно на гистограмме. Один выраженный пик в центре и примерно симметричные спады влево и вправо: форма «колокол». Это визуальный признак близости к нормальному распределению.

1.2 Почему можно думать о нормальности. Для нормального распределения теоретически $\gamma_1 = 0$ и $\gamma_2 = 0$. В реальных выборках (даже при истинной нормальности) выборочные γ_1, γ_2 почти никогда не равны нулю ровно, потому что выборка конечна, и есть случайные флуктуации.

Здесь $\gamma_1 = -0.31$ — небольшая отрицательная асимметрия (левый хвост чуть тяжелее), но по правилу внимательности это не катастрофа. Эксцесс $\gamma_2 = 0.95$ уже заметен: это сигнал, что хвосты/пик могут быть чуть тяжелее, чем у идеальной нормали. Практически это означает: **нормальность как рабочая гипотеза допустима**, но при строгом тестировании (например, тест Шапиро–Уилка) может потребоваться проверка.

1.3 Почему среднее и медиана близки. При симметрии (или почти симметрии) центральная точка по «балансу» и по «половинкам» совпадает. Формально:

- среднее $\overline{x}$ использует все x_i и является центром массы;
- медиана Me определяется условием «50% слева и 50% справа».

Если распределение симметрично, то эти определения приводят к близким числам, и разница вызвана случайностью.

1.4 Как понимать дисперсию и s. Дисперсия $s^2 = 103.29$ означает, что типичный квадрат отклонения от среднего около 103. Стандартное отклонение $s = 10.16$ означает: типичное отклонение от среднего порядка 10 единиц. Если бы распределение было идеально нормальным, то примерно:

$$\text{около } 68\% \text{ наблюдений в } [\overline{x} - s, \overline{x} + s], \quad 95\% \text{ в } [\overline{x} - 2s, \overline{x} + 2s],$$

это знаменитое «правило 68–95–99.7» для нормального распределения.

1.5 Вывод. Гистограмма унимодальна и почти симметрична; среднее и медиана близки; это согласуется с рабочей гипотезой нормальности. При этом эксцесс 0.95 просит осторожности: хвосты могут быть тяжелее.

Пример 2. Смесь двух нормальных (бимодальность), $n = 100$

Дано: среднее 50.73, медиана 48.97, дисперсия 201.15, $s = 14.18$, асимметрия $\gamma_1 = 0.03$, эксцесс $\gamma_2 = -0.58$. На гистограмме два пика и «провал» между ними.

2.1 Что видно на гистограмме. Два выраженных пика (две моды). Это ключевой визуальный признак: данные, скорее всего, состоят из двух разных подгрупп.

2.2 Почему при бимодальности среднее становится «плохим». Среднее по определению:

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Если выборка — смесь двух подгрупп с центрами μ_1 и μ_2, то теоретически

$$\mathbb{E}X = p\mu_1 + (1-p)\mu_2.$$

Если μ_1 и μ_2 достаточно разнесены, то $p\mu_1 + (1-p)\mu_2$ может оказаться **между** пиками, то есть в зоне, где наблюдений мало (в «провале»). Тогда среднее не описывает ни одну из подгрупп как «типичное значение».

2.3 Почему асимметрия почти нулевая, но распределение не нормальное. Асимметрия $\gamma_1 \approx 0$ говорит лишь о том, что «левый и правый хвосты» суммарно могут быть похожи. Но **нулевая асимметрия не гарантирует нормальность**. Можно иметь симметричную бимодальную смесь: два пика на одинаковом расстоянии от центра дают почти нулевую асимметрию.

2.4 Почему медиана тоже не спасает. Медиана делит выборку пополам, но при двух подгруппах она может попасть в «провал» или сместиться к более многочисленной группе. Она может быть устойчивее к выбросам, но **не является лекарством от неоднородности**.

2.5 Правильное решение задачи «что делать». В практикуме сформулировано корректно:

1. не сглаживать гистограмму: бимодальность — важная информация;
2. проверить устойчивость двух пиков (другая ширина бинов, больший объём данных);
3. искать скрытый фактор (пол, оборудование, время, регион и т.д.);
4. если фактор неизвестен, можно применить кластеризацию, чтобы выделить группы.

2.6 Подробно: как работает кластеризация (как в вашем практикуме). В практикуме задана исходная отсортированная выборка $n = 100$ и начальные центры $c_1 = 40$, $c_2 = 70$.

Шаг 1 (присваивание точек). Каждое наблюдение x_i относим к ближайшему центру:

$$x_i \in G_1 \text{ если } |x_i - c_1| \le |x_i - c_2|, \qquad x_i \in G_2 \text{ иначе.}$$

Шаг 2 (пересчёт центров). После разбиения пересчитываем центры как средние внутри групп:

$$c_1 = \frac{1}{n_1} \sum_{x_i \in G_1} x_i, \qquad c_2 = \frac{1}{n_2} \sum_{x_i \in G_2} x_i.$$

Интерпретация итераций, которые у вас получились. В практикуме:

- Итерация 1: $n_1 = 59,\ c_1 \approx 40.82$; $n_2 = 41,\ c_2 \approx 65.00$;
- Итерация 2: $n_1 = 56,\ c_1 \approx 40.14$; $n_2 = 44,\ c_2 \approx 64.22$;
- Итерация 3: центры не меняются, значит алгоритм стабилизировался.

Это означает: данные действительно естественно делятся на две подгруппы с центрами около 40.1 и 64.2.

2.7 Что важнее всего после кластеризации. После выделения групп **каждую группу нужно анализировать отдельно**: свои средние, свои медианы, свои дисперсии. Именно это и делает практикум: показывает, что после разбиения каждая подгруппа становится унимодальной и «более нормальной».

Пример 3. Экспоненциальное распределение, $n = 100$

Дано: среднее 41.65, медиана 33.26, дисперсия 567.28, $s = 23.82$, асимметрия $\gamma_1 = 1.92$, эксцесс $\gamma_2 = 3.89$. Гистограмма: пик у левого края, длинный хвост вправо.

3.1 Почему это похоже на экспоненциальное распределение. Экспоненциальное распределение имеет плотность

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0,$$

и всегда выглядит так: много маленьких значений и редкие большие значения (правый хвост).

3.2 Почему среднее больше медианы (очень важная логика). У экспоненциального распределения:

$$\mathbb{E}X = \frac{1}{\lambda}, \qquad \mathrm{Me} = \frac{\ln 2}{\lambda}.$$

Так как $\ln 2 < 1$, то $\mathrm{Me} < \mathbb{E}X$. Это ровно то, что мы видим: $33.26 < 41.65$.

3.3 Почему асимметрия большая и положительная. Положительная асимметрия означает «хвост справа длинный». Ваша $\gamma_1 = 1.92$ большая: это количественное подтверждение сильной правой асимметрии.

3.4 Почему эксцесс большой и положительный. Большой $\gamma_2 = 3.89$ означает тяжёлые хвосты: редкие большие значения встречаются заметно чаще, чем «по нормальному». Для экспоненциального распределения это естественно: хвост есть всегда.

3.5 Какую меру центра выбирать и почему. Если цель — описать «типичное значение» основной массы данных, то среднее будет сильно сдвинуто хвостом. Медиана устойчивее, поэтому в правоскошенных распределениях её часто предпочитают как характеристику центра.

Пример 4. Равномерное распределение, $n = 100$

Дано: среднее 49.98, медиана 49.08, дисперсия 324.90, $s = 18.02$, асимметрия $\gamma_1 = 0.09$, эксцесс $\gamma_2 = -1.23$. Гистограмма «плоская» (нет выраженного пика).

4.1 Почему это похоже на равномерное распределение. У равномерного распределения на $[a, b]$ все значения примерно одинаково вероятны, поэтому гистограмма без явного пика. Плотность:

$$f(x) = \frac{1}{b-a}, \quad x \in [a, b].$$

4.2 Почему эксцесс отрицательный. Равномерное распределение более «плоское», чем нормальное: нет выраженного пика. Отрицательный эксцесс как раз является признаком плоской формы. Значение около -1.2 очень типично для равномерного вида.

4.3 Почему среднее и медиана почти равны. Равномерное распределение симметрично относительно середины интервала, поэтому теоретически

$$\mathbb{E}X = \mathrm{Me} = \frac{a+b}{2}.$$

В выборке получаются близкие значения.

4.4 Почему важно указывать границы диапазона. Для равномерного распределения центральные меры мало что добавляют без информации о размахе. Главные параметры — a и b (минимум и максимум), потому что они определяют и среднее, и дисперсию:

$$\mathrm{Var}(X) = \frac{(b-a)^2}{12}.$$

Поэтому при интерпретации равномерного распределения всегда сообщают диапазон $[x_{\min}, x_{\max}]$.

Пример 5. Нормальное распределение + выбросы, $n = 100$

Дано: среднее 52.47, медиана 51.30, дисперсия 161.44, $s = 12.71$, асимметрия $\gamma_1 = 1.71$, эксцесс $\gamma_2 = 4.71$. Гистограмма: «колокол» в центре и отдельные столбики справа, отделённые зазором.

5.1 Что это означает визуально. Основная масса данных действительно похожа на нормальную (унимодальная, почти симметричная), но справа присутствует группа значений, далёкая от основной массы. Это выглядит как **выбросы** или отдельная подгруппа.

5.2 Почему среднее становится больше медианы. Среднее чувствительно к большим значениям:

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{n} x_i.$$

Если несколько значений очень большие, они «тянут» сумму вверх, значит и среднее растёт. Медиана почти не реагирует на несколько экстремальных значений, потому что зависит от порядка, а не от величины хвоста. Поэтому при выбросах обычно:

$$\overline{x} > \mathrm{Me}.$$

В вашей ситуации разница ≈ 1.17 уже заметна на фоне нормального вида основной массы.

5.3 Почему асимметрия и эксцесс резко выросли. Выбросы справа создают длинный правый хвост, поэтому γ_1 становится большим и положительным. А эксцесс γ_2 растёт, потому что в формуле 4-я степень усиливает вклад дальних точек:

$$\gamma_2 = \frac{1}{n}\sum\left(\frac{x_i - \overline{x}}{s}\right)^4 - 3.$$

Если есть несколько очень больших x_i, то $(x_i - \overline{x})^4$ огромны, значит эксцесс растёт сильно.

5.4 Какую меру центра выбирать. Если ваша цель — описать основную массу данных, то медиана лучше отражает центр «колокола», чем среднее. Среднее описывает «центр всей смеси», включая выбросы, и может вводить в заблуждение.

5.5 Что делать с выбросами (логика, а не автоматизм). Корректный принцип (и он прямо сформулирован в практике): **не удалять выбросы автоматически**. Сначала нужно понять природу:

- это ошибка ввода/измерения?
- это другая категория объектов (вторая подгруппа)?
- это редкие, но реальные события (тяжёлый хвост)?

Только после интерпретации принимают решение: корректировка, отдельный анализ, робастные методы (медиана, усечённые средние), и т.д.

Итоговая «шпаргалка»: как принимать решение по гистограмме

1. Если один пик и почти симметрия, то среднее и s обычно информативны; допускается гипотеза нормальности.

2. Если два пика, то нужно искать скрытый фактор; среднее может быть «в провале» и быть плохой характеристикой.

3. Если пик у левого края и длинный хвост вправо, то это похоже на экспоненциальное: медиана лучше описывает «типичное».

4. Если гистограмма плоская, а эксцесс отрицательный, то это похоже на равномерное: важно сообщать диапазон.

5. Если «колокол» + отдельные столбики далеко, то вероятны выбросы/подгруппа: среднее искажается, медиана устойчивее.

Места для рисунков из PDF

Если вы хотите вставить картинки гистограмм из вашего файла «Практика 2», добавьте их в проект Overleaf и раскомментируйте: