Задачи по лекции 1 (предмет математической статистики, статистические модели)

Указания к задачам

Все задания построены по материалу *Лекции 1*: выборка и её реализация, выборочное пространство, пример оценивания вероятности в схеме Бернулли, генеральная совокупность, простая выборка, параметрическая модель Φ_θ, вариационный ряд и порядковые статистики, эмпирическая частота $\nu_n(x)$ и эмпирическая функция распределения $F_n(x)$, свойства $EF_n(x) = F_\xi(x)$ и $DF_n(x) = \dfrac{F_\xi(x)(1 - F_\xi(x))}{n}$, а также гистограмма и полигон частот *(включая формулы $h_j = a_j - a_{j-1}$ и высоту $\frac{n_j}{nh_j}$)*. См. текст лекции: определения и формулы на стр. 1–4 [**?**].

Ниже приведены 20 задач с подробными решениями.

Задачи и решения

Задача 1 (Выборка и реализация)**.** *Эксперимент повторяется $n = 6$ раз. Получены результаты измерений:*

$$(12,\ 15,\ 11,\ 14,\ 13,\ 16).$$

Запишите (а) реализацию выборки $x = (x_1, \ldots, x_n)$; (б) объясните, почему величины $X_1, \ldots, X_n$ нельзя считать числами до проведения эксперимента.

Решение. *(а) Реализация выборки уже дана:*

$$x = (x_1, \ldots, x_6) = (12, 15, 11, 14, 13, 16).$$

(б) До проведения эксперимента $X_1, \ldots, X_n$ являются случайными величинами: если повторить серию из n опытов, получатся другие значения. Следовательно, до наблюдения это не фиксированные числа, а случайные величины с одним и тем же законом распределения (как у ξ). Это соответствует формулировке лекции: $X = (X_1, \ldots, X_n)$ — конечная совокупность СВ, а $x = (x_1, \ldots, x_n)$ — её реализация.

Задача 2 (Выборочное пространство)**.** *Пусть в каждом эксперименте измеряется величина, которая может принимать значения только из множества $\{0, 1, 2\}$. Найдите выборочное пространство $\mathcal{X}$ для выборки объёма $n = 3$.*

Решение. *Выборочное пространство — множество всех возможных значений выборки $x = (x_1, x_2, x_3)$. Здесь каждый $x_i \in \{0, 1, 2\}$, поэтому*

$$\mathcal{X} = \{0, 1, 2\}^3 = \{(a, b, c) \mid a, b, c \in \{0, 1, 2\}\}.$$

Мощность $|\mathcal{X}| = 3^3 = 27$.

Задача 3 (Схема Бернулли: построение X_i)**.** *Проводятся $n = 10$ испытаний, в каждом фиксируется событие A (успех). В конкретной серии успехи получены в испытаниях*

$$1, 2, 4, 5, 7, 8, 10.$$

Запишите реализацию $(x_1, \ldots, x_{10})$ случайных величин

$$X_i = \begin{cases} 1, & \text{если } A \text{ произошло,} \\ 0, & \text{если } A \text{ не произошло.} \end{cases}$$

Найдите $S_{10} = X_1 + \cdots + X_{10}$ и $\overline{X} = \dfrac{S_{10}}{10}$.

Решение. *Успехи в 1,2,4,5,7,8,10, значит*

$$(x_1, \ldots, x_{10}) = (1, 1, 0, 1, 1, 0, 1, 1, 0, 1).$$

Число успехов:

$$S_{10} = 1 + 1 + 0 + 1 + 1 + 0 + 1 + 1 + 0 + 1 = 7.$$

Среднее:

$$\overline{X} = \frac{S_{10}}{10} = \frac{7}{10} = 0.7.$$

По лекции $\overline{X}$ логично рассматривать как оценку $P(A) = p$.

Задача 4 (Схема Бернулли: оценивание p по частоте)**.** *В серии из $n = 50$ испытаний события A наблюдалось $S_{50} = 18$ раз. Постройте оценку вероятности $p = P(A)$ по правилу лекции и интерпретируйте результат.*

Решение. *В лекции в качестве оценки вероятности предлагается среднее значение:*

$$\widehat{p} = \overline{X} = \frac{S_n}{n}.$$

Следовательно,

$$\widehat{p} = \frac{18}{50} = 0.36.$$

Интерпретация: по данным серии испытаний доля успехов составляет 36%, поэтому разумно считать, что истинная вероятность успеха близка к 0.36 (качество оценки обсуждается позже).

Задача 5 (Генеральная совокупность и простая выборка)**.** *Объясните, что в лекции называют генеральной совокупностью и почему выборку $X = (X_1, \ldots, X_n)$ называют простой, если X_i независимы и одинаково распределены как ξ.*

Решение. *По определению лекции генеральная совокупность — это множество значений случайной величины ξ вместе с её функцией распределения $F_\xi(x)$. То есть генеральная совокупность описывает вероятностную модель явления. Выборка $X = (X_1, \ldots, X_n)$ называется простой, если компоненты X_i независимы и имеют один и тот же закон распределения, что и ξ. Тогда выборка — n-мерная СВ, описывающая исход испытания, а «простота» означает i.i.d.-структуру.*

Задача 6 (Параметрическая модель Φ_θ)**.** *Для каждой ситуации укажите класс Φ и параметр θ:*

1. *(Бернулли)* $X_i \in \{0, 1\}$, *неизвестна вероятность успеха.*
2. *(Нормальная) измеряется величина, предполагается* $N(\mu, \sigma^2)$, μ, σ *неизвестны.*
3. *(Показательная) время ожидания* T, *предполагается* $F(t) = 1 - e^{-\lambda t}$ *при* $t \geq 0$, λ *неизвестно.*

Решение. 1. Φ — *семейство распределений Бернулли; параметр* $\theta = p \in (0, 1)$.
2. Φ — *семейство нормальных распределений; параметр* $\theta = (\mu, \sigma)$, *где* $\sigma > 0$.
3. Φ — *семейство показательных распределений; параметр* $\theta = \lambda > 0$.

Во всех случаях неизвестная функция распределения принадлежит классу Φ, *заданному с точностью до* $\theta \in \Theta$, *поэтому модель параметрическая* Φ_θ.

Задача 7 (Вариационный ряд реализации)**.** *Дана реализация выборки*

$$x = (0, 11, 2, 3, 9, 2, 8, 6, 3, 4, 8, 7, 5, 9, 4, 8, 6).$$

Постройте вариационный ряд реализации (упорядочьте по возрастанию).

Решение. *Отсортируем значения. Подсчёт по значениям:*

$$0(1),\ 2(2),\ 3(2),\ 4(2),\ 5(1),\ 6(2),\ 7(1),\ 8(3),\ 9(2),\ 11(1).$$

Итого $n = 17$. *Вариационный ряд:*

$$0,\ 2,\ 2,\ 3,\ 3,\ 4,\ 4,\ 5,\ 6,\ 6,\ 7,\ 8,\ 8,\ 8,\ 9,\ 9,\ 11.$$

Задача 8 (Порядковые статистики)**.** *Для выборки из предыдущей задачи найдите* $x_{(1)}$, $x_{(5)}$, $x_{(9)}$, $x_{(17)}$.

Решение. *Из вариационного ряда:*

$$x_{(1)} = 0, \quad x_{(5)} = 3, \quad x_{(9)} = 6, \quad x_{(17)} = 11.$$

Задача 9 (Эмпирическая частота $\nu_n(x)$)**.** *Для той же выборки* ($n = 17$) *вычислите эмпирическую частоту* $\nu_n(6)$ *и* $\nu_n(9)$, *где* $\nu_n(x)$ — *число элементов выборки, меньших* x.

Решение. *Вариационный ряд:*

$$0,\ 2,\ 2,\ 3,\ 3,\ 4,\ 4,\ 5,\ 6,\ 6,\ 7,\ 8,\ 8,\ 8,\ 9,\ 9,\ 11.$$

Чисел < 6 *восемь (это* $0, 2, 2, 3, 3, 4, 4, 5$*), значит*

$$\nu_n(6) = 8.$$

Чисел < 9 *четырнадцать (все до первых* 9, *то есть до позиции 14 включительно), значит*

$$\nu_n(9) = 14.$$

Задача 10 (Эмпирическая функция распределения $F_n(x)$)**.** *Для выборки из задач 7–9 вычислите* $F_n(6)$ *и* $F_n(9)$.

Решение. *По определению эмпирическая функция распределения:*

$$F_n(x) = \frac{\nu_n(x)}{n}.$$

Так как $n = 17$, *получаем*

$$F_n(6) = \frac{8}{17}, \qquad F_n(9) = \frac{14}{17}.$$

Задача 11 (Явный вид $F_n(x)$ для простой выборки)**.** *Пусть все значения выборки различны и вариационный ряд реализации равен*

$$x_{(1)} < x_{(2)} < \cdots < x_{(n)}.$$

Запишите кусочно-постоянный вид $F_n(x)$, совпадающий с формулой лекции.

Решение. *Если все $x_{(k)}$ различны, эмпирическая функция распределения имеет вид ступенчатой функции:*

$$F_n(x) = \begin{cases} 0, & x \le x_{(1)}, \\ \frac{k}{n}, & x_{(k)} < x \le x_{(k+1)}, \quad k = 1, \ldots, n-1, \\ 1, & x > x_{(n)}. \end{cases}$$

Смысл: при прохождении точки наблюдения функция возрастает на $1/n$.

Задача 12 (Распределение эмпирической частоты)**.** *Пусть $X = (X_1, \ldots, X_n)$ — простая выборка из ξ. Рассмотрим событие "успех" $\{\xi < x\}$. Объясните, почему $\nu_n(x)$ имеет биномиальное распределение $B_{n, F_\xi(x)}$.*

Решение. *По определению $\nu_n(x)$ — число элементов выборки, меньших x. Рассмотрим n независимых испытаний, где успехом считается событие $\{X_i < x\}$. Тогда вероятность успеха в каждом испытании равна*

$$P(X_i < x) = P(\xi < x) = F_\xi(x),$$

поскольку X_i распределены как ξ. Число успехов в n независимых испытаниях Бернулли имеет биномиальное распределение. Следовательно,

$$\nu_n(x) \sim B\big(n,\ F_\xi(x)\big).$$

Задача 13 (Математическое ожидание $F_n(x)$)**.** *Используя факт $\nu_n(x) \sim B(n, F_\xi(x))$, докажите, что*

$$E\, F_n(x) = F_\xi(x).$$

Решение. *Так как $F_n(x) = \dfrac{\nu_n(x)}{n}$, то*

$$E\, F_n(x) = E\left(\frac{\nu_n(x)}{n}\right) = \frac{1}{n} E\, \nu_n(x).$$

Для биномиального распределения $B(n, p)$ известно, что $E\, \nu_n(x) = np$, где $p = F_\xi(x)$. Значит,

$$E\, F_n(x) = \frac{1}{n} \cdot n F_\xi(x) = F_\xi(x).$$

Задача 14 (Дисперсия $F_n(x)$)**.** *Пусть $\nu_n(x) \sim B(n, F_\xi(x))$. Выведите формулу*

$$D\, F_n(x) = \frac{F_\xi(x)\big(1 - F_\xi(x)\big)}{n}.$$

Решение. *Так как* $F_n(x) = \dfrac{\nu_n(x)}{n}$, *то*

$$D\,F_n(x) = D\left(\frac{\nu_n(x)}{n}\right) = \frac{1}{n^2} D\,\nu_n(x).$$

Для биномиального $B(n,p)$: $D\,\nu_n(x) = np(1-p)$, *где* $p = F_\xi(x)$. *Следовательно,*

$$D\,F_n(x) = \frac{1}{n^2}\cdot nF_\xi(x)\big(1-F_\xi(x)\big) = \frac{F_\xi(x)\big(1-F_\xi(x)\big)}{n}.$$

Задача 15 (Числовая оценка дисперсии $F_n(x)$)**.** *Пусть* $n = 100$ *и известно, что* $F_\xi(2) = 0.3$. *Найдите* $D\,F_n(2)$.

Решение. *По формуле*

$$D\,F_n(x) = \frac{F_\xi(x)(1-F_\xi(x))}{n}$$

получаем

$$D\,F_n(2) = \frac{0.3\cdot(1-0.3)}{100} = \frac{0.3\cdot 0.7}{100} = 0.0021.$$

Задача 16 (Построение группировки для гистограммы)**.** *Дана выборка*

$$x = (0, 11, 2, 3, 9, 2, 8, 6, 3, 4, 8, 7, 5, 9, 4, 8, 6).$$

Постройте группированную выборку при разбиении отрезка $[a_0; a_k]$ *на 4 интервала одинаковой длины, где* $a_0 = x_{(1)}$, $a_k = x_{(n)}$.

Решение. *Из вариационного ряда:* $a_0 = x_{(1)} = 0$, $a_k = x_{(n)} = 11$. *Разобьём* $[0; 11]$ *на 4 равных интервала: длина*

$$h = \frac{11-0}{4} = 2.75.$$

Интервалы можно взять полузамкнутыми:

$$[0, 2.75),\ [2.75, 5.5),\ [5.5, 8.25),\ [8.25, 11].$$

Подсчитаем числа, попавшие в каждый интервал. По исходным данным:

- $[0, 2.75)$: *значения* $0, 2, 2 \Rightarrow n_1 = 3$;
- $[2.75, 5.5)$: *значения* $3, 3, 4, 4, 5 \Rightarrow n_2 = 5$;
- $[5.5, 8.25)$: *значения* $6, 6, 7, 8, 8, 8 \Rightarrow n_3 = 6$;
- $[8.25, 11]$: *значения* $9, 9, 11 \Rightarrow n_4 = 3$.

Проверка: $3 + 5 + 6 + 3 = 17 = n$. *Это и есть группированная выборка (частоты по интервалам).*

Задача 17 (Высоты прямоугольников гистограммы)**.** *Для группировки из предыдущей задачи найдите высоты прямоугольников гистограммы по формуле лекции*

$$\text{высота}_j = \frac{n_j}{n\,h},$$

где h *— длина интервала (одинаковая для всех).*

Решение. *Здесь* $n = 17$, $h = 2.75$. *Тогда*

$$\text{высота}_1 = \frac{3}{17 \cdot 2.75}, \quad \text{высота}_2 = \frac{5}{17 \cdot 2.75}, \quad \text{высота}_3 = \frac{6}{17 \cdot 2.75}, \quad \text{высота}_4 = \frac{3}{17 \cdot 2.75}.$$

Численно:

$$17 \cdot 2.75 = 46.75.$$

Следовательно,

$$\text{высота}_1 = \frac{3}{46.75} \approx 0.0642, \quad \text{высота}_2 = \frac{5}{46.75} \approx 0.1069, \quad \text{высота}_3 = \frac{6}{46.75} \approx 0.1283, \quad \text{высота}_4 = \frac{}{46}$$

Задача 18 (Проверка площадей прямоугольников)**.** *Покажите, что площадь j-го прямоугольника гистограммы равна частоте попадания в соответствующий интервал, то есть*

$$h \cdot \frac{n_j}{n\,h} = \frac{n_j}{n}.$$

Решение. *По формуле высота равна* $\dfrac{n_j}{n\,h}$, *ширина равна* h. *Тогда площадь:*

$$\text{площадь}_j = h \cdot \frac{n_j}{n\,h} = \frac{n_j}{n}.$$

То есть площадь прямоугольника равна относительной частоте попадания в интервал, как утверждается в лекции.

Задача 19 (Полигон частот: координаты точек)**.** *Для гистограммы из задачи 16 (4 равных интервала) выпишите координаты точек полигона частот, если полигон проходит через середины верхних границ прямоугольников.*

Решение. *Интервалы:*

$$[0, 2.75),\ [2.75, 5.5),\ [5.5, 8.25),\ [8.25, 11].$$

Середины:

$$m_1 = \frac{0 + 2.75}{2} = 1.375, \quad m_2 = \frac{2.75 + 5.5}{2} = 4.125, \quad m_3 = \frac{5.5 + 8.25}{2} = 6.875, \quad m_4 = \frac{8.25 + 11}{2} = 9.62$$

Высоты из задачи 17:

$$y_1 \approx 0.0642,\ y_2 \approx 0.1069,\ y_3 \approx 0.1283,\ y_4 \approx 0.0642.$$

Точки полигона частот:

$$(1.375,\ 0.0642),\ (4.125,\ 0.1069),\ (6.875,\ 0.1283),\ (9.625,\ 0.0642).$$

Задача 20 (Связь эмпирической ФР и теоретической: оценка по ЗБЧ)**.** *Объясните на примере события* $\{X < x\}$, *почему по закону больших чисел эмпирическая функция распределения* $F_n(x)$ *приближает* $F_\xi(x)$ *при больших* n.

Решение. *Рассмотрим индикаторы* $I_i = \mathbf{1}_{\{X_i < x\}}$. *Тогда* I_i *независимы, одинаково распределены и*

$$E\,I_i = P(X_i < x) = F_\xi(x).$$

Сумма $\nu_n(x) = I_1 + \cdots + I_n$ *— число элементов выборки, меньших* x*, а*

$$F_n(x) = \frac{\nu_n(x)}{n} = \frac{1}{n}\sum_{i=1}^{n} I_i$$

— среднее индикаторов. По закону больших чисел среднее независимых одинаково распределённых СВ стремится к их математическому ожиданию, поэтому

$$F_n(x) \xrightarrow{P} F_\xi(x) \quad (n \to \infty).$$

Интуитивно: доля наблюдений меньше x *стабилизируется около истинной вероятности события* $\{\xi < x\}$*.*

Задача 21 (Вариант: вычислить $F_n(x)$ по таблице значений)**.** *Дана выборка из* $n = 8$ *наблюдений:*

$$x = (2, 5, 1, 4, 4, 3, 6, 2).$$

Постройте вариационный ряд, затем вычислите $F_n(4)$*,* $F_n(2)$ *и* $F_n(7)$*.*

Решение. *Упорядочим:*

$$1, 2, 2, 3, 4, 4, 5, 6.$$

Эмпирическая частота $\nu_n(x)$ *— число элементов, меньших* x*.*

Для $x = 4$ *меньше 4:* $1, 2, 2, 3$ *(4 элемента), значит*

$$F_n(4) = \frac{4}{8} = 0.5.$$

Для $x = 2$ *меньше 2: только* 1 *(1 элемент), значит*

$$F_n(2) = \frac{1}{8} = 0.125.$$

Для $x = 7$ *меньше 7: все 8 элементов, значит*

$$F_n(7) = \frac{8}{8} = 1.$$